빅데이터분석 4 주차 팀과제 보고서

방과후 청소년 공간 후보 자치구 분석

서울시 생활인구 15~18 시(3 시간) 10 대 절대 규모와 비중 교차

과 목	빅데이터분석
담당교수	박주원
조 / 미션	14 조 / 미션 D
팀 원	박유진 · 신효주 · 정승엽
자료 저장소	github.com/202103116-stack/youth-space-seoul-analysis
Colab 노트북	Colab(박유진) | Colab(신효주) | Colab(정승엽)

2026. 10. 14.

14 조

목 차

I. 분석 개요 1
1. 과제와 판단 기준 1
2. 가설 1
3. 반대 결과 수용 기준 1
II. 데이터 이해 2
1. 수집 기록 2
2. 측정 척도 2
III. 탐색 3
1. 원본 구조와 첫인상 3
2. 이상 징후 3
3. 정제 전 1 차 집계 3
IV. 정제 3
1. 데이터 품질 진단 3
2. 정제 원칙과 순서 4
3. 정제 처리 로그 5
4. 정제 결과 6
V. 결론 8
1. 절대 · 비중 상위 자치구 8
2. 두 지표의 교차 8
3. 가설 검증 9
4. 반대 결과 수용 9
5. 결론 3 요소 10
VI. 부록 11
1. 재현성 확인표 11
2. 기여표 12
3. AI 활용 기록 13

I. 분석 개요

1. 과제와 판단 기준

□ 의사결정자는 청소년정책 담당자이며, 방과후(15~18 시) 10 대가 많이 머무는 자치구에 청소년 공간을 새로 열려 함

□ 후보 자치구는 두 지표를 함께 보고 고름

○ **절대**: 15~18 시 10 대 생활인구 합계(명)

○ **비중**: 같은 시간대 전 연령대 합계 대비 10 대 비율(%)

□ "15~18 시"는 시간대 값 15 · 16 · 17 의 3 개 구간으로 계산함. 시간대 값 X 는 X 시~X+1 시를 뜻하므로 18 시 구간(18:00~19:00)은 범위에서 제외함

※ 팀 Colab 노트북: https://colab.research.google.com/drive/1s3vgx2A4SzmbloHruZYMK9oj0jM5dcXV?usp=sharing (링크가 있는 모든 사용자 보기 가능). 생활인구 CSV 만 올린 상태에서 "런타임 → 다시 시작 및 모두 실행"으로 끝까지 실행됨을 확인함(2026. 10. 14., 코드 셀 35 개, 오류 0 건). 지도용 자치구 경계 파일은 노트북이 팀 GitHub 저장소에서 내려받음.

2. 가설

□ **절대**: 방과후 10 대 생활인구는 거주지보다 학원 · 학교 등 교육시설이 밀집한 자치구에 몰릴 것. 따라서 절대 상위 3 개 구에 대표 학원가인 **강남구 · 양천구 · 노원구**가 다수 포함될 것

□ **비중**: 업무 · 상업 유동인구까지 많은 번화한 학원가(강남구 · 송파구)는 다른 연령대에 희석되어 비중이 낮고, 학원가이면서 주거 비중이 높은 베드타운형 **노원구**에서 비중이 더 두드러질 것

□ 학원가 자치구는 학원 수 · 주간인구지수 관련 보도자료로 미리 골라 둠(부록 3 의 #1). 이 자료는 가설을 세울 때만 쓰고, 분석 결과 해석에는 쓰지 않음

3. 반대 결과 수용 기준

반대 결과도 받아들임. 절대 · 비중 상위 자치구가 학원가 목록(강남 · 양천 · 노원)과 무관하게 나오면 "학원가 밀집" 가설을 기각하고, 공원 · 대형 상업시설 · 환승거점 · 산업단지 통근 인구

같은 비학업적 체류 요인으로 설명을 바꿈. 이때 이 데이터가 하루치 교육용 가공 데이터라는 한계도 결론에 함께 적음.

II. 데이터 이해

1. 수집 기록

[표 1] 수집 기록표

항목	내용
데이터명	서울시_생활인구_202604_dl0830.csv
제공처	수업 담당교수 제공(강의 공통 데이터)
원 출처(추정)	서울시 생활인구 통계 형식을 본뜬 교육용 가공 데이터
수집·제공 시점	2026 년 4 주차 수업
기준일자	2026-04-15 (하루)
규모(정제 전)	3,860 행 × 5 열, 인코딩 CP949
주의	**교육용으로 오류를 일부러 넣은 가공 데이터임. 실제 서울시 공식 통계가 아니므로 결론을 실제 정책 근거나 사실로 인용하지 않음**

2. 측정 척도

척도는 정제 후 올바르게 해석한 값(예: 생활인구수를 숫자로 바꾼 뒤)을 기준으로 분류함. 정제 전 저장 형식(문자열 등)과는 기준이 다름.

[표 2] 컬럼별 측정 척도

컬럼	척도	설명
기준일자	명목(날짜)	전부 2026-04-15 한 값이라 분석 변수로 쓰지 않음
자치구	명목	서울시 25 개 자치구. 순서·크기 비교 의미 없음
시간대	등간(구간)	0~23 시, 1 시간 간격. 간격은 같지만 0 시가 "없음"을 뜻하지 않음
연령대	서열	10 대 < 20 대 < … < 60 대이상. 순서는 있으나 구간 폭이 다름(60 대이상은 상한 없음)
생활인구수	비율	명 단위 추정 인구. 0 이 "없음"이고 몇 배인지 비교할 수 있음

III. 탐색

1. 원본 구조와 첫인상

□ 3,860 행 × 5 열. 자치구 25 개, 시간대 0~23 시, 연령대 6 종이 모두 빠짐없이 들어 있음

□ 생활인구수만 콤마・“-“・빈칸이 섞여 숫자가 아닌 문자열로 읽힘

□ 컬럼명 3 개(기준일자, 자치구, 연령대)에 앞뒤 공백이 있어 그대로는 컬럼을 부를 때 오류가 남

2. 이상 징후

[표 3] 정제 전 이상 징후 7 종

#	이상 징후	건수	특징
1	생활인구수 빈칸	95	20 대·40 대·60 대이상에서만 발생
2	완전 중복 행	260 쌍	모든 값이 같은 행이 정확히 2 번씩 등장
3	음수	25	그중 2 건은 -9990(특수 오류값)
4	"-" 표기	100	10 대·30 대·50 대에서만 발생, 빈칸과 겹치지 않음
5	비정상 고값	19	동대문구 2~4 시에만 50 만~80 만. 1,000 으로 나누면 앞뒤 시간대와 비슷
6	컬럼명 공백	3 개 컬럼	기준일자·자치구·연령대
7	콤마 표기 혼재	360	"3,909"와 "3287"이 한 컬럼에 섞임

3. 정제 전 1 차 집계

미션 범위(15~17 시・10 대)로 거르면 82 행이 나옴. 기대값 75 행(25 개 구 × 3 개 시간대)보다 7 행 많고, 이 7 행은 완전 중복 행임. 정제 없이 집계하면 10 대 합계가 부풀려진다는 뜻이라 정제가 필요함.

IV. 정제

1. 데이터 품질 진단

데이터 품질 6 대 기준(완전성・유일성・유효성・정확성・일관성・적시성) 순서로 문제를 정리함.

[표 4] 품질 기준별 문제 (정제 전)

기준	문제	건수	세부 내용
완전성	생활인구수 빈칸	95 건	값이 비어 있음
유일성	완전 중복 행	260 건	5 개 컬럼이 모두 같은 행. 중복에 얽힌 행은 520 행
유효성	음수	25 건	-9990 2 건(특수 오류값 추정), 나머지 23 건은 -417 ~ -7,804
유효성	"-" 표기	100 건	숫자 대신 "-" 문자로 기록
정확성	비정상 고값	19 건	동대문구 2~4 시에만 50 만~80 만. 같은 구 다른 시간대는 577~3,756 수준
일관성	컬럼명 공백	3 개	기준일자·자치구·연령대
일관성	콤마 표기 혼재	360 건	천 단위 콤마가 있는 값과 없는 값이 섞임
적시성	기준일자	이상 없음	전체가 2026-04-15 한 날짜

2. 정제 원칙과 순서

모든 이슈를 고치지 않음. 분석 범위(15~17 시) 안에 영향이 있을 때만 고치고, 손대지 않은 것은 이유를 남김. 절대는 10 대(분자), 비중은 같은 시간대 전 연령대(분모)를 쓰므로 분모에 영향이 있는 이슈도 처리 대상임.

[표 5] 정제 순서와 그 이유

순서	단계	하는 일	적용 범위	이 순서인 이유
0	사전 진단	범위 기준 행 수·이슈 건수만 셈	-	범위 안 영향 여부를 보고 처리 여부를 정하려고
1	공백 제거	컬럼명·값 앞뒤 공백 제거	전체	이후 모든 코드가 깨지지 않게 가장 먼저
2	숫자 변환	콤마 제거 후 숫자형 변환("-"·빈칸은 결측)	전체	숫자여야 중복·음수·합계를 판단할 수 있음
3	중복 제거	완전 중복 행 제거	전체	중복이 보정 평균과 합계를 부풀리지 않게
4	음수 처리	-9990 은 결측, 나머지는 부호 복원	전체	보정 평균에 정상값만 들어가게
5	결측 보정	같은 구·연령대의 범위 내 평균으로 채움	**범위 안만**	중복·음수 정리 뒤라야 평균이 정확
6	확인만	동대문구 고값·기준일자 확인	-	범위 안 0 건임을 코드로 확인

순서	단계	하는 일	적용 범위	이 순서인 이유
7	최종 점검	필터 전후 행 수, 자동 점검(assert)	-	0 행이나 숫자 불일치를 잡으려고

3. 정제 처리 로그

[표 6] 처리 내역과 판단 근거

#	처리	건수	근거	판단
1	컬럼명 공백 제거	컬럼명 3 개 / 값 0 셀	공백 때문에 컬럼 호출 시 오류	채택. 값 쪽 공백은 없어 결과 영향 없음
2	콤마 제거 후 숫자 변환	전체 360 → 범위 50(10 대 6)	문자열이라 합계·평균 불가	채택. 변환 후 결측 195 건은 전부 "-"·빈칸이라 손실 없음
3	완전 중복 행 제거	전체 260 → 범위 35(10 대 7)	같은 행이 2 번씩 등장, 값만 다른 충돌 행은 0 건	채택. 안 하면 10 대 합계가 7 행만큼 부풀려짐. 제거 후 미션 범위 75 행으로 기대값과 일치
4	음수: -9990 은 결측, 나머지 부호 복원	전체 23 → 범위 2(10 대 0)	절대값(417~7,804)이 정상 범위와 비슷해 부호만 잘못 붙은 것으로 판단	채택. 범위 안 2 건(용산구 17 시 60 대이상, 노원구 16 시 30 대)은 비중 분모에만 영향
5	빈칸: 범위 안 분모만 평균 보정	범위 15 → 중복 제거 후 13	10 대에는 없으나 분모에 들어가 비워 두면 비중이 부풀려짐	보정함(팀 확정 2026. 10. 9.). 절대 순위는 그대로, 비중 순위는 25 개 구 중 21 개 변동
6	"-": 범위 안 분모만 평균 보정	범위 12 → 중복 제거 후 9	범위 안 10 대 "-"는 0 건, 30·50 대만 분모에 영향	보정함. 범위 밖 10 대 "-"는 영향 없어 그대로 둠
7	동대문구 새벽 고값	전체 19 → 범위 0	2~4 시에만 발생, 단위 오류 추정	손대지 않음. 범위 밖이라 결과 영향 없고, 고치면 근거 없는 변경이 됨
8	기준일자 확인	0 건	전체가 한 날짜, 형식 이상 없음	손대지 않음. 하루치라는 점은 한계로 적음

결측 보정(5・6 번)은 비중 순위를 크게 바꾸므로, 실제 코드를 아래에 그대로 실음. 같은 구・같은 연령대의 15~17 시 평균으로 채우고, 범위 밖 결측은 건드리지 않음.

```
# 결정 적용: 범위 안 분모 결측(빈칸 + '-')을 같은 구·연령대 평균으로 채움
n_filled = int((miss & scope).sum())
n_filled_blank = int(t2.loc[' 결측: 빈칸', '범위·전 연령'])
n_filled_dash = int(t2.loc[" 결측: '-'", '범위·전 연령'])
if DENOM_MISSING == 'impute':
    clean = imputed
    assert clean.loc[in_scope(clean), '생활인구수'].notnull().all(), '보정 후에도 범위 안 결측이 남음(같은 구·연령대 3개 시간대가 모두 결측?)'
print(f"DENOM_MISSING = '{DENOM_MISSING}' 적용 | 범위 안 결측 남은 건수:", int((clean['생활인구수'].isnull() & in_scope(clean)).sum()),
      '| 범위 밖 결측(손대지 않음):', int((clean['생활인구수'].isnull() & ~in_scope(clean)).sum()))

_decision = '팀 확정(2026-10-09): 보정함' if DENOM_MISSING == 'impute' else '팀 확정: 보정 안 함'
_effect = (f'절대 순위는 보정 전후 동일(10대는 보정 대상 아님). 비중은 순위 변동 {rank_changed}/{N_GU}개 자치구, 상위5 구성 동일={top5_same}')

log.append(dict(처리='결측(빈칸): 범위 안 분모는 같은 구·연령대 평균으로 보정, 범위 밖은 그대로', 건수=flow(' 결측: 빈칸'),
    근거='빈칸은 20·40·60대이상에만 있어 10대(분자)는 해당 없음. 그러나 비중의 분모(전 연령대)에 들어가므로 비워 두면 그 구의 분모가 작아져 비중이 부풀',
    영향=f'{_decision} — 범위 안 빈칸 {n_filled_blank}건 보정. {_effect}. 범위 밖 빈칸은 영향이 없어 손대지 않음'))

log.append(dict(처리="결측('-'): 범위 안 10대는 해당 없음, 범위 안 분모는 같은 구·연령대 평균으로 보정, 범위 밖은 그대로", 건수=flow(" 결측: '-'"),
    근거="10대 '-'는 범위(15~17시) 안에 0건이라 절대(합계)는 보정할 것이 없음(범위 안에 생기면 assert로 멈춤). 30·50대 '-'는 분모에 들어가므로 빈칸과",
    영향=f"{_decision} — 범위 안 '-' {n_filled_dash}건 보정(30대·50대). 범위 밖 10대 '-'는 영향이 없어 손대지 않음"))
```

✓ 0.0s Python

```
DENOM_MISSING = 'impute' 적용 | 범위 안 결측 남은 건수: 0 | 범위 밖 결측(손대지 않음): 159
```

[그림 1] 분모 결측 보정 코드 (팀 노트북 STEP④ D)

4. 정제 결과

이슈마다 원본, 중복 제거 후, 정제 후 세 단계에서 전체·범위 전 연령·범위 10 대 건수를 같은 기준으로 셈. 범위 안 칸이 모두 0 이 되었는지, 범위 밖에 남긴 것이 무엇인지 한 표에서 확인할 수 있음.

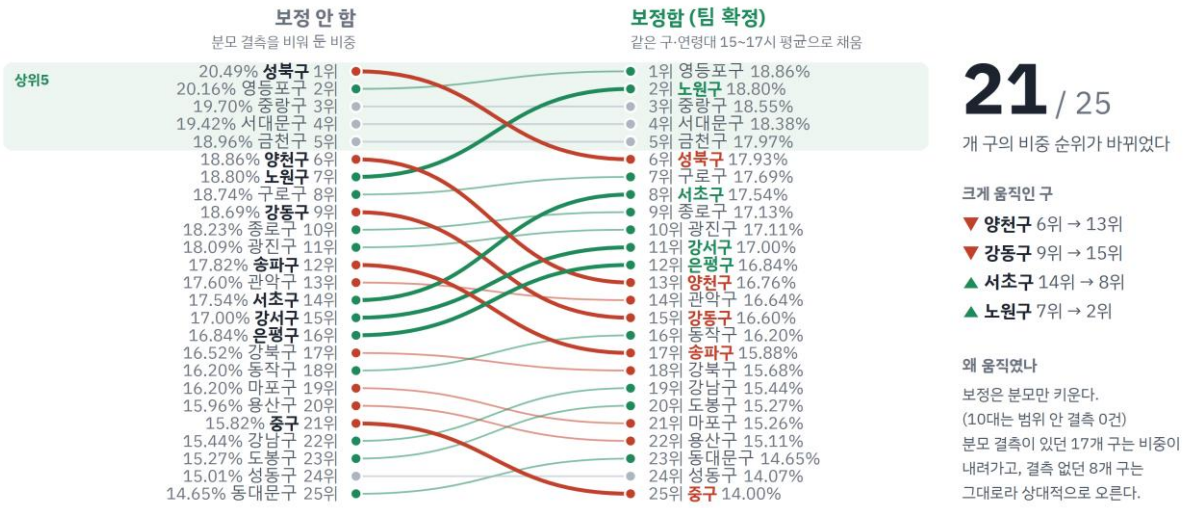


[그림 2] 이슈별 건수 단계별 추적표 (원본 → 중복 제거 후 → 정제 후)

☐ 전체 3,860 행 → 3,600 행, 미션 범위(15~17 시 · 10 대) 82 행 → 75 행으로 25 개 구 × 3 개 시간대와 정확히 일치함

☐ 범위 안 결측·음수는 0 건이 됨. 남은 결측 159 건과 동대문구 고값 18 건은 모두 범위 밖이라 그대로 둠

□ 분모 결측 보정은 절대 순위에는 영향이 없지만 비중 순위는 25 개 구 중 21 개를 바꿈. 보정하지 않으면 비중 1 위가 성북구(20.49%)로 나옴



[그림 3] 분모 결측 보정 전후 비중 순위 이동 (왼쪽 보정 안 함, 오른쪽 보정함)

```
m_after = mission(clean)
print(f"정제 전 전체 행 수              : {len(df)}")
print(f"정제 후 전체 행 수              : {len(clean)}")
print(f"미션 범위 필터 전 → 후 (정제 전) : {len(df)} → 전 연령대 {len(scope_all)}행 / 10대 {len(mission(df))}행")
print(f"미션 범위 필터 전 → 후 (정제 후) : {len(clean)} → 전 연령대 {int(in_scope(clean).sum())}행 / 10대 {len(m_after)}행")

assert len(m_after) > 0, '필터 결과가 0행 — 코드가 아니라 조건(시간대·연령대 값)을 의심'
assert len(m_after) == N_GU * N_HOURS
assert int(in_scope(clean).sum()) == N_GU * N_HOURS * N_AGES
assert clean.loc[in_scope(clean), '생활인구수'].notnull().all() and (clean.loc[in_scope(clean), '생활인구수'] >= 0).all()
assert m_after['자치구'].nunique() == N_GU
print('\n점검 통과: 범위 안은 자치구', N_GU, '개 × 시간대', N_HOURS, '개 × 연령대', N_AGES, '=', N_GU * N_HOURS * N_AGES, '행(전 연령대),',
      N_GU * N_HOURS, '행(10대), 결측·음수 없음')

pd.DataFrame(log, index=range(1, len(log) + 1))
```

✓ 0.0s Python

```
정제 전 전체 행 수              : 3860
정제 후 전체 행 수              : 3600
미션 범위 필터 전 → 후 (정제 전) : 3860 → 전 연령대 485행 / 10대 82행
미션 범위 필터 전 → 후 (정제 후) : 3600 → 전 연령대 450행 / 10대 75행

점검 통과: 범위 안은 자치구 25 개 × 시간대 3 개 × 연령대 6 = 450 행(전 연령대), 75 행(10대), 결측·음수 없음
```

[그림 4] 정제 후 최종 점검 코드와 실행 결과

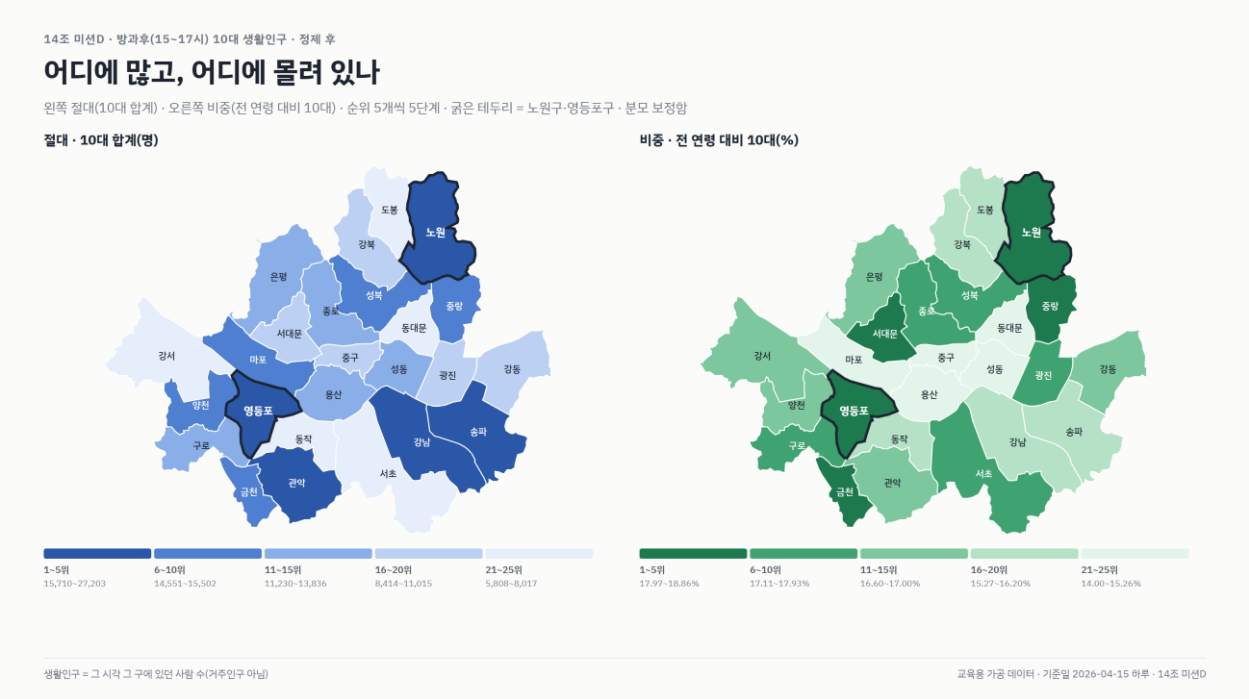
V. 결론

1. 절대 · 비중 상위 자치구

[표 7] 절대 · 비중 상위 5 개 자치구 (정제 후, 15~17 시)

순위	절대: 자치구	10 대 합계(명)	비중: 자치구	10 대 비중(%)
1	강남구	27,203	영등포구	18.86
2	송파구	22,698	노원구	18.80
3	관악구	21,055	중랑구	18.55
4	영등포구	20,223	서대문구	18.38
5	노원구	15,710	금천구	17.97

같은 결과를 지도에 놓으면 두 지표의 분포가 다르게 보임. 절대는 강남・송파 등 동남권이 진하고, 비중은 영등포・노원・중랑 등 서남・동북권이 진함.

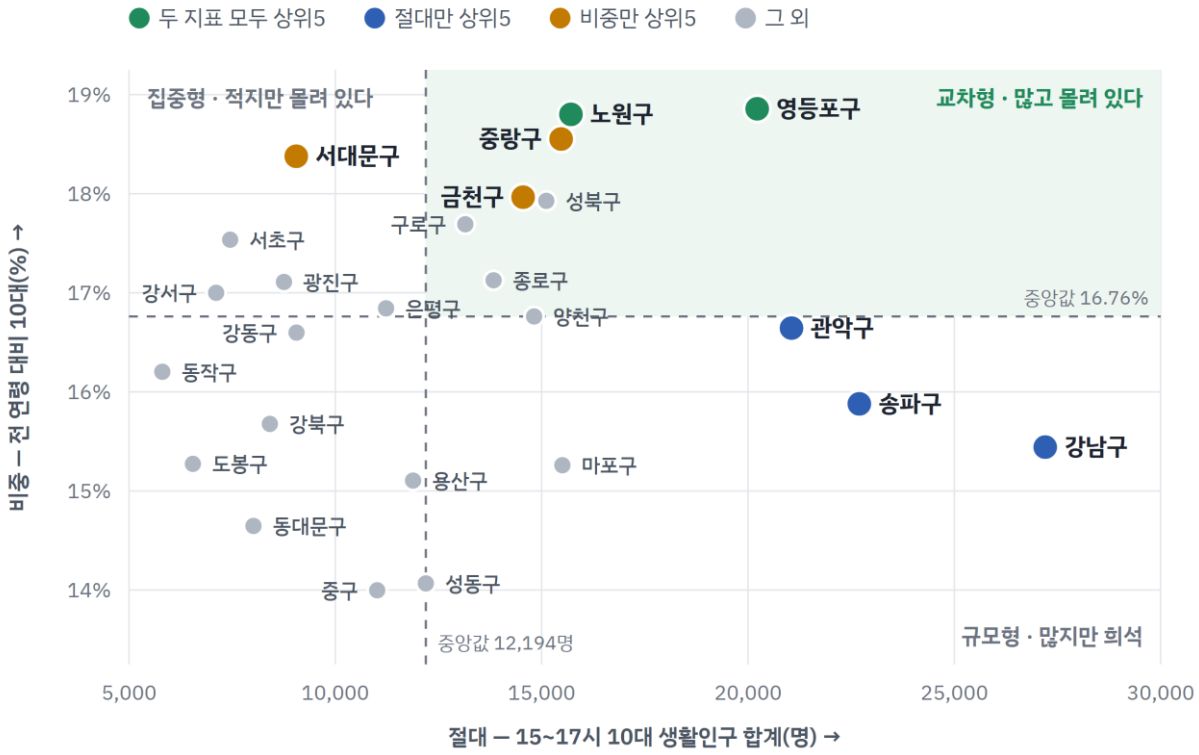


[그림 5] 자치구별 10 대 절대 규모(왼쪽)와 비중(오른쪽) 지도

2. 두 지표의 교차

절대 상위 5 개(강남・송파・관악・영등포・노원)와 비중 상위 5 개(영등포・노원・중랑・서대문・금천)에 모두 드는 자치구는 **노원구와 영등포구** 두 곳뿐임. 기준을 중앙값 이상으로 넓히면 구로・금천・성북・양천・종로・중랑도 들어오지만, 상위 5 개

교차만큼 강한 근거는 아님. 또한 비중 1 위 영등포구(18.86%)와 2 위 노원구(18.80%)는 0.06%p 차이라 사실상 동률이고, 비중 상위 5 개도 모두 1%p 안(17.97~18.86%)에 몰려 있어 순위 하나하나보다 상위 5 개 묶음으로 보는 것이 맞음.



[그림 6] 자치구별 10 대 절대 규모와 비중 (점선은 각 지표의 중앙값)

3. 가설 검증

□ **절대 예측은 틀림.** 절대 상위 3 개(강남 · 송파 · 관악) 중 가설의 학원가(강남 · 양천 · 노원)는 강남 한 곳뿐임(양천 9 위, 노원 5 위)

○ 송파(2 위)는 가설에서 이미 "번화한 학원가"로 분류한 곳이라 설명이 되지만, 관악(3 위)은 학원가 목록에 없던 반대 결과임

□ **비중 예측은 대체로 맞음.** 강남(19 위, 15.44%) · 송파(17 위, 15.88%)는 비중이 낮고 노원은 2 위(18.80%)로, 번화한 학원가일수록 비중이 희석된다는 설명과 맞음

○ 다만 비중 1 위는 가설에 없던 영등포구(18.86%)임

4. 반대 결과 수용

관악구(절대 3 위)와 영등포구(비중 1 위)는 미리 정한 학원가 목록 밖의 반대 결과임. 수용 기준에 따라 "학원가 밀집" 하나로 설명하는 것을 기각하고, 상업시설 · 환승거점 · 통근 인구 같은 비학업적 요인과 함께 설명하는 쪽으로 바꿈. 다만 이 데이터에는 학원 · 상업시설 정보가 없어 두 구에 10 대가 많은 이유를 증명할 수는 없으며, 이는 추측으로 채우지 않고 한계로 남김.

5. 결론 3 요소

가. 권고안

□ **노원구・영등포구**를 확정 후보로 하고, 세 번째 후보는 판단을 보류함

○ 노원구: 절대 5 위(15,710 명), 비중 2 위(18.80%). 가설이 예측한 “학원가이면서 주거지“ 유형과 맞음

○ 영등포구: 절대 4 위(20,223 명), 비중 1 위(18.86%). 두 지표 모두 최상위권이라 가장 강한 근거. 학원가 통념과는 무관한 반대 결과라 현장 확인이 필요함

○ 세 번째 후보: 규모를 우선하면 강남구(절대 1 위, 27,203 명), 집중도를 우선하면 중랑구(비중 3 위, 18.55%). 정책 목적(최대 다수 대 효율)을 정한 뒤 고름

나. 근거

10 대 절대 합계와 비중을 교차했을 때 양쪽 상위 5 개에 모두 드는 자치구는 노원구와 영등포구뿐임(표 7, 그림 6). 절대 순위는 분모 결측 보정 여부와 관계없이 같고, 영등포구는 보정 전후 모두 비중 2 위 안에 들어 결론이 정제 판단에 크게 흔들리지 않음(그림 3).

다. 한계

□ **하루치 데이터**: 2026-04-15 하루, 교육용으로 오류를 넣은 가공 데이터라 실제 서울시 경향과 다를 수 있고, 요일・학기・방학에 따른 차이도 볼 수 없음

□ **생활인구에는 주민과 외부 유입이 섞여 있음**: 15~17 시 생활인구에는 그 구에 사는 10 대와 통학・학원 때문에 다른 구에서 온 10 대가 함께 포함되어 있으나, 이 데이터에는 거주지 정보가 없어 둘을 나눌 수 없음

□ **15~17 시는 팀이 정한 구간**: 데이터에서 찾은 구간이 아니라 팀이 “방과후“로 정의한 구간이며, 분모 결측 보정 여부에 따라 비중 순위가 21 개 구에서 바뀜. 이 순위는 “이번 정제 기준에서의 결과“로 봐야 함

VI. 부록

1. 재현성 확인표

팀원 3 명이 각자 자기 계정에서 제출 노트북(공유 Colab)을 "런타임 → 다시 시작 및 모두 실행"으로 처음부터 실행해 핵심 숫자가 같은지 확인함(표 8). 원본 기록은 `logs/재현성_확인표.md`에 있음.

[표 8] 제출 노트북 재실행 결과 (각자 계정에서 공유 Colab 실행)

확인 항목	박유진	신효주	정승엽
오류 없이 완주	O (오류 없음)	O (assert 모두 통과)	O (코드 셀 35 개, 오류 0)
정제 후 최종 행 수	3,600	3,600	3,600
미션 범위 행 수	75	75	75
절대 1 위	강남구 27,203 명	강남구 27,203 명	강남구 27,203 명
비중 1 위(보정 후)	영등포구 18.86%	영등포구 18.86%	영등포구 18.86%
실행 일시(KST)	2026-10-14 22:56	2026-10-14 23:01	2026-10-14 17:09
실행 환경	본인 계정	본인 계정	본인 계정
실행 노트북	팀 최종 노트북(공유 Colab)		

추가로 각자 다른 환경 · 코드(로컬 Jupyter, 개인 Colab 노트북)로도 처음부터 다시 실행해 같은 숫자가 나오는지 확인했고(표 9), 이 과정에서 아래 두 가지를 발견함.

[표 9] 추가 검증: 각자 다른 환경 · 코드로 다시 실행한 결과

확인 항목	박유진	신효주	정승엽
오류 없이 완주	O (수정본 재실행, 오류 0)	O	O (코드 셀 35 개, 오류 0)
정제 후 최종 행 수	3,600	3,600	3,600
미션 범위 행 수	75	75	75
절대 1 위	강남구 27,203 명	강남구 27,203 명	강남구 27,203 명
비중 1 위(보정 후)	영등포구 18.86%	영등포구 18.86%	영등포구 18.86%
실행 일시(KST)	2026-10-13(원본) 2026-10-14(수정본 재실행)	2026-10-14 15:45	2026-10-14 16:15

확인 항목	박유진	신효주	정승엽
실행 환경	Colab, 개인 노트북 Colab(수정본)	Colab, 개인 노트북 Colab	로컬 Jupyter(Python 3.11.9, pandas 3.0.6), 새 커널 전체 실행 팀 최종 노트북 Colab

□ **발견 1 (숨은 상태)**: 박유진 노트북은 저장된 출력이 팀 결과와 같았지만, 범위 안 분모 결측 22 건을 채우는 셀이 빠져 있었음. 정제 셀 출력은 결측 181 건인데 다음 검증 셀은 159 건(181 − 22)이고, 전 연령 합계에 `101585.5` 같은 .5 값(평균 보정의 흔적)이 남아 있어 찾아냄. 그대로 다시 돌리면 비중 1 위가 성북구(20.49%)로 바뀌는 상태였음

○ 보정 셀을 다시 넣자 `KeyError: '자치구'`가 남. 원본 CSV 컬럼명 앞의 공백(“ 자치구“)을 값에서만 지우고 컬럼명에서는 지우지 않았던 것이 원인이었음

○ `clean.columns = clean.columns.str.strip()` 한 줄을 추가하고 출력을 모두 지운 수정본을 처음부터 재실행함. 보정 전 22 건 → 보정 후 0 건, 남은 결측 159 건, 절대 상위 5 개와 비중 1 위(영등포구 18.86%)가 팀 수치와 모두 같아 O 로 갱신함(2026. 10. 14.)

□ **발견 2 (별도 코드로 재현)**: 신효주 노트북은 팀 노트북을 복사하지 않고 AI(Claude)의 도움을 받아 13 개 셀로 새로 작성한 코드인데도(부록 3 의 #14) 행 수(3,860→3,600, 범위 485→450, 10 대 82→75)와 절대 · 비중 상위 5 개가 모두 같았음

2. 기여표

[표 10] 단계별 역할 (● 초안, ○ 교차 검토)

단계	자료·질문 (박유진)	보고서·발표 (신효주)	AI 실행·검증 (정승엽)
① 질문 정의	○	●	○
② 데이터 이해	●	○	○
③ 탐색	○	○	●
④ 정제	○	○	●
⑤ 결론	●	●	○
재현성 확인	●	●	●

3. AI 활용 기록

AI 에 맡긴 작업은 "무엇을 물었는가, 무엇을 받았는가, 어떻게 검증했는가, 채택했는가" 순서로 기록함. 아래는 요약이며 프롬프트 원문은 저장소의 `logs/AI 활용기록.md` 에 있음.

[표 11] AI 활용 기록 요약

#	날짜	단계	물은 것	받은 것	검증	판단
1	10-08	가설 근거	강남·양천·노원·송파가 학원 밀집·주거 비중이 높은 구인지 자료로 확인	학원가 보도 3 건, 주간인구지수·베드타운 보도 2 건	기사 원문 5 건을 직접 열어 수치·주체 확인	채택(가설 근거로만 사용)
2	10-08	자료구조	생활인구수의 콤마·"-" 표기 확인	예시만 보여주는 코드 → 전수 건수 코드로 보완 요청	콤마 360·"-" 100 건이 사전 진단과 일치	채택
3	10-09	탐색	이상 징후 7 종을 모두 코드로 확인	결측 95, 중복 260 쌍, 음수 25, "-" 100, 고값 19, 공백 3, 콤마 360	직접 실행해 7 개 모두 일치	채택
4	10-09	사전 진단	데이터를 바꾸지 않고 범위 기준 이슈 건수 추적	범위 485 행(10 대 82) → 450(75), 단계별 추적표	원본 건수를 탐색 결과와 대조, assert 통과	채택
5	10-09	공백	컬럼명·값 공백 점검과 제거	컬럼명 3 개, 값 0 셀	원본 CSV 헤더와 대조	채택
6	10-09	숫자 변환	콤마 제거 후 숫자 변환, 손실 확인	결측 195 = "-" 100 + 빈칸 95	assert 통과	채택
7	10-09	음수	범위·10 대 해당 여부를 먼저 세고 -9990 과 구분	23 건, 범위 안 2 건은 모두 분모	절대값이 같은 구·연령대 정상 범위 안인지 확인	채택
8	10-09	결측	분모 결측을 보정 안 함/평균 보정으로 비교	절대는 같고 비중 상위 5 개가 달라짐	두 방식 상위 5 개를 직접 실행	**수정**(기존 팀 결정 정정)
9	10-09	결측 확정	범위 안 분모 결측 22 건 평균 보정	22 건 보정, 범위 밖 159 건 유지	보정 후 결측 0 assert, 몇 건 직접 열어 봄	채택
10	10-09	확인만	동대문구 고값·기준일자가 범위 안에 있는지	고값 18 건 모두 2~4 시, 기준일자 1 개	범위 안 0 건 assert	채택(수정 안 함)
11	10-09	중복	완전 중복 제거와 충돌 행 확인	260 행 제거, 범위 35 행(10 대 7), 충돌 0	미션 범위 75 행 assert	채택
12	10-09	최종 점검	필터 전후 행 수와 정제 로그를 코드로 생성	3,860→3,600, 82→75, 로그 8 줄	처음부터 다시 실행해 같은 숫자 확인	채택
13	10-13	보고서 정리	팀 기록을 바탕으로 보고서 문장 정리(Claude)	보고서 초안, 표 4 오기 2 건 지적	원본 CSV 로 핵심 수치 재계산해 일치 확인	채택(문장 수정)
14	10-14	재현	팀 기준으로 처음부터 실행되는 노트북 코드 작성(Claude)	13 개 셀 코드와 기대 결과값	Colab 에서 다시 시작 및 모두 실행, 팀 수치와 일치	채택

AI 가 낸 수치는 모두 직접 실행해 확인한 뒤에만 보고서에 적었음. 팀 결정과 어긋난 결과(#8)는 근거와 함께 수정 사유를 남김.