빅데이터분석 4주차 팀과제 · 미션 D

방과후 10대는 어디에 머무는가

15~17시 10대 생활인구로 청소년 공간을 열 자치구 고르기

1 **무엇을 봤는가**
미션 · 데이터 · 함정

2 **어떻게 했는가**
핵심 정제 판단

3 **그래서 무엇인가**
권고 · 근거 · 한계

14조 정승엽 · 박유진 · 신효주

교육용으로 오류가 의도적으로 삽입된 가공 데이터(기준일 2026-04-15 하루) — 실제 서울시 공식 통계가 아닙니다.

미션: 방과후 10대가 많이 머무는 구에 공간을 연다

미션 (고정)

의사결정자	청소년정책 담당자
결정	방과후 청소년 공간을 새로 열 자치구
범위	15~18시 · 10대 → 15·16·17시 3개 시간대

절대 = 합계

10대 합계

얼마나 많이 머무나

자치구별 15~17시
10대 생활인구 · 단위 명

비중 = 비율

10대 ÷ 전 연령

얼마나 몰려 있나

분모 = 같은 시간대
전 연령대 합계 · 단위 %

우리 가설 (분석 전에 세움)

**방과후 10대는 사는 곳이 아니라
학원·학교가 몰린 구에 머물 것이다**

- 절대 상위3에 학원가 강남·양천·노원이 다수 들어갈 것
- 비중은 번화한 학원가(강남·송파)보다 학원가 + 주거지인 노원에서 두드러질 것

반대 결과 수용 (미리 정해 둔 규칙)

학원가 밖의 구가 상위에 오르면 가설을 기각하고,
상업시설·환승거점·통근 같은 비학업 요인으로 설명을 바꾼다.

데이터와 함정: 숫자를 믿기 전에 확인한 세 가지

서울시 생활인구(가공) 3,860행 × 5열 · 25개 구 × 24개 시간대 × 6개 연령대 · 2026-04-15 하루치

함정 1

생활인구 ≠ 거주인구

그 시각 그 구에 있던 사람 수다. 다른 구에서 통학해 온 학생도 함께 잡힌다.

함정 2

오류가 심어진 데이터

교육용으로 중복·결측·음수·고값·콤마 표기를 일부러 넣었다. 그대로 더하면 틀린다.

함정 3

'15~18시'는 피크가 아니다

7~20시가 전반적으로 평평하다. 15~17시는 데이터가 아니라 우리가 정한 '방과후'다.

원본에서 찾은 품질 이슈 전부 고치지 않고, 15~17시 범위에 영향이 있는지부터 확인했다

260
완전 중복 행

195
결측 (빈칸 95 · '-' 100)

25
음수 (−9990 2건 포함)

19
고값 (동대문 새벽 2~4시)

360
콤마 표기 값

정제 순서: 앞 단계가 뒤 단계의 입력을 깨끗하게 만든다

진단	형식 정리		명백한 오류 교정		모르는 값 추정	확인	
0	1	2	3	4	5	6	7
사전 진단	공백 제거	숫자 변환	중복 제거	음수 처리	결측 보정	손대지 않음	최종 점검
변경 없음	전체	전체	전체	전체	범위 안만	확인만	assert
범위 안 영향부터 센다	컬럼명 공백에 코드가 깨지지 않게	숫자가 돼야 합계·중복·음수를 판단	합계·평균이 부풀지 않게	정상값만 평균에 들어가게	정리된 값으로 평균을 내 채움	고값·기준일자는 기록만	0행 무음 실패·수치 불일치 차단
		핵심 판단 ①		핵심 판단 ②	범위 한정		

순서가 곧 이유 숫자로 바꿔야 음수와 표기만 다른 중복을 찾을 수 있고, 중복·음수를 먼저 정리해야 결측 보정 평균이 오염되지 않는다. 분석용 필터링(15~17시)은 정제가 끝난 뒤에 한다.

핵심 판단 두 가지: 숫자 변환, 음수 처리

핵심 판단 ①

'1,234'는 더할 수 없다

원본		정제 후
"1,234"	→	1234
"1234"	→	1234
"-" · 빈칸	→	NaN (결측)

문제 콤마 있는 값과 없는 값이 섞여 열 전체가 문자열이다. 합계를 낼 수 없다. (360건, 범위 안 10대 6건)

처리 콤마를 지우고 숫자형으로 바꿨다. 문자 '-'와 빈칸은 NaN이 된다.

검증 변환 후 NaN 195건 = 원래 '-'·빈칸 195건. 변환 때문에 잃은 값은 0건이다.

핵심 판단 ②

인구는 음수일 수 없다, 규칙은 둘

원본		정제 후
−9990	→	NaN (결측)
그 밖의 음수	→	abs()로 부호 복원
예: −417	→	417

근거 −9990은 인구 범위를 벗어난 오류코드다. 나머지 음수의 절대값(417~7,804)은 정상 인구 범위 안에 있다.

처리 −9990(2건)은 결측으로, 나머지 23건은 부호만 되돌렸다. 행은 지우지 않았다.

영향 범위 안 2건 모두 분모(전 연령)다. 10대 합계는 그대로, 비중의 분모만 바로잡혔다.

어디까지 고칠까: 틀린 값은 전체, 모르는 값은 범위 안만

판단 기준은 하나 이 값은 '틀린' 값인가, '모르는' 값인가?

틀렸다 전체 표에 적용

명백한 오류 교정

공백 제거 | 숫자 변환 | 중복 제거 | 음수 규칙

- 인구가 음수일 수 없다는 사실은 15~17시에만 참인 게 아니다.
- 정제된 표는 24시간 히트맵에도 다시 쓰인다. 범위 밖 오류를 남기면 그 그래프가 오염된다.

모른다 범위(15~17시) 안에서만

모르는 값 추정

결측 보정 22건

- 범위 밖 결측은 절대·비중 어디에도 쓰이지 않는다.
- 채울수록 근거 없는 추정값만 늘어난다. 그래서 범위 밖 결측 159건은 그대로 뒀다.

손대지 않은 것도 이유와 함께 기록 동대문구 새벽 고값 18건(범위 밖) · 범위 밖 결측 159건 · 기준일자(단일 날짜, 형식 이상 없음)

정제 결과: 범위 안 문제는 0건, 행 수는 기대값과 일치

STEP④ 정제 · 이슈별 건수 단계별 추적 · 범위 = 15·16·17시

범위 안 문제는 모두 0건으로, 범위 밖은 이유를 남기고 그대로

0 정제로 해결 | 18 범위 밖 · 의도적으로 유지 | 7 결과를 왜곡하는 값 | 0 원래 없음

이슈	① 원본 3,860행			② 중복 제거 후 3,600행 · 260행 제거			③ 정제 후 (잔여) 음수 복원 · 범위 안 결측 보정		
	전체	범위 전 연령(분모)	범위 10대(분자)	전체	범위 전 연령(분모)	범위 10대(분자)	전체	범위 전 연령(분모)	범위 10대(분자)
(참고) 행 수 기대값 3,600 / 450 / 75	3,860	485	82	3,600	450	75	3,600	450	75
완전 중복 행(2회째)	260	35	7 (A)	0	0	0	0	0	0
결측 합계	195	27	0 (B)	180	22	0	159 (D)	0 (C)	0
└ 빈칸	95	15	0	89	13	0	·	·	·
└ '-'	100	12	0	91	9	0	·	·	·
음수(부호 오류 추정)	23	2	0	22	2	0	0	0	0
특수코드 -9990	2	0	0	1	0	0	0	0	0
고값(>10만, 동대문 새벽)	19	0	0	18	0	0	18 (E)	0	0
콤마 포함(형식)	360	50	6	338	47	5	0	0	0

읽는 법

A 중복 7행이 10대 합계를 부풀림
범위 안 10대 중복 7행을 지우지 않으면 절대(10대 합계)가 그만큼 커집니다. 제거 후 75행 = 25구 × 3시간대로 기대값과 일치.

B 10대 결측은 처음부터 0건
빈칸·'-' 모두 범위 안 10대는 0건이라 절대(분자)는 보정할 것이 없습니다. 10대 '-' 35건은 전부 범위 밖.

C 분모 결측 22건 → 0건
빈칸 13 + '-' 9건이 비중의 분모(전 연령)에 있어, 같은 구·연령대의 15~17시 평균으로 보정했습니다. 안 하면 비중이 부풀려집니다.

D 남은 결측 159건은 전부 범위 밖
`180 − 22 + 1 = 159` (-9990을 결측으로 바꾼 1건 포함). 결과에 쓰이지 않아 추정값으로 채우지 않았습니다.

E 동대문구 새벽 고값 18건은 수정 안 함
2~4시에만 있는 단위 오류 추정값. 15~17시 밖이라 절대·비중 어디에도 영향이 없어 그대로 둡니다.

· 숫자 변환 후에는 빈칸과 '-'를 구분할 수 없어 따로 세지 않음(결측 합계 줄로 확인) | 0 센 결과 남은 게 없음

데이터: 교육용 가공 데이터(오류 의도 삽입), 기준일 2026-04-15 하루 · 14조 미션D

필터 전 → 후 행 수

전체

3,860 → **3,600**

중복 260행 제거

범위 · 전 연령 (분모)

485 → **450**

= 25구 × 3시간 × 6연령

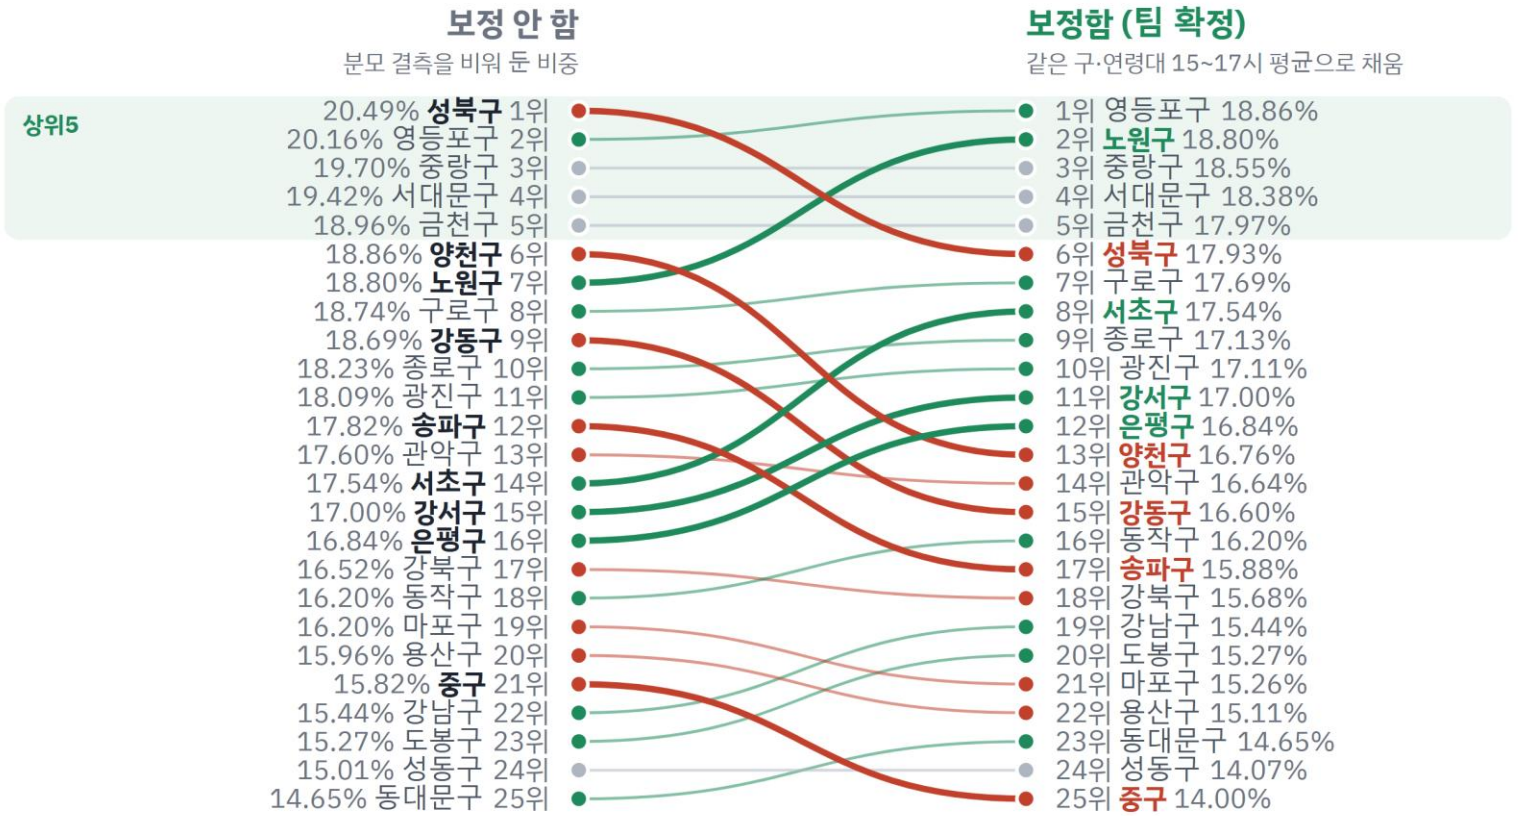
범위 · 10대 (분자)

82 → **75**

= 25구 × 3시간

기대값과 정확히 맞아서 필터 조건(15~17시)이 맞다는 것도 함께 검증했다. 0행이 나오면 코드보다 조건을 의심한다.

분모 결측을 보정하자 비중 순위가 크게 바뀌었다



21 / 25

개 구의 비중 순위가 바뀌었다

크게 움직인 구

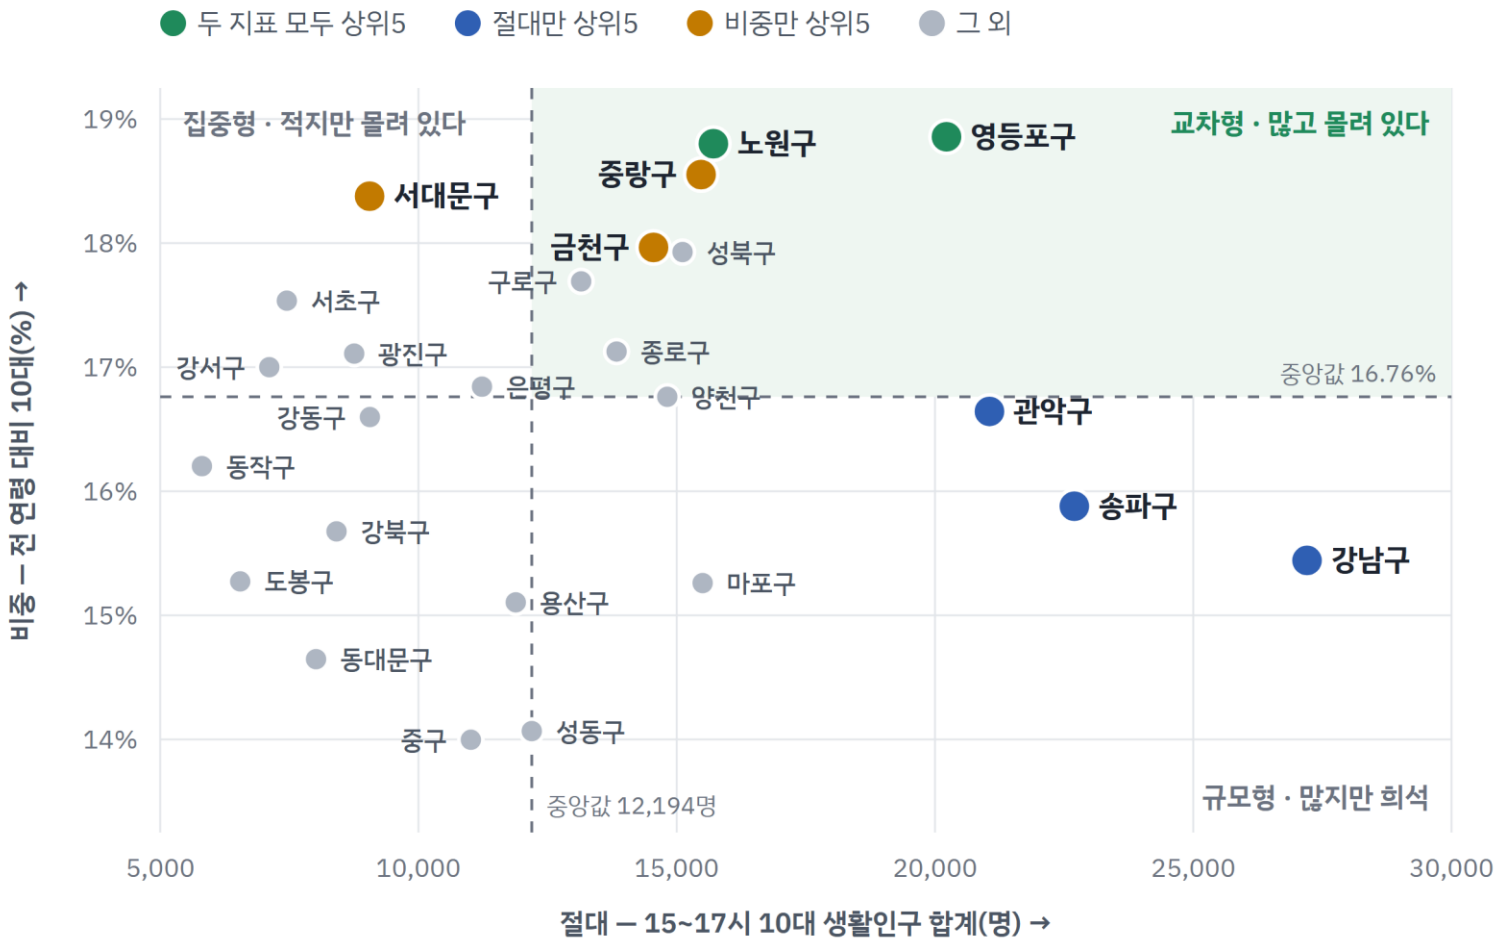
- ▼ **양천구** 6위 → 13위
- ▼ **강동구** 9위 → 15위
- ▲ **서초구** 14위 → 8위
- ▲ **노원구** 7위 → 2위

왜 움직였나

보정은 분모만 키운다.
(10대는 범위 안 결측 0건)
분모 결측이 있던 17개 구는 비중이 내려가고, 결측 없던 8개 구는 그대로라 상대적으로 오른다.

읽는 법 보정은 분모만 키운다 → 결측이 있던 구는 내려오고, 없던 구(노원 등)는 그대로라 올라선다. 순위가 이렇게 흔들리는 걸 보고도 보정했으므로 결론은 '이번 정제 기준의 결과'(한계 ③)

결과: 두 지표 모두 상위5에 든 구는 노원·영등포뿐



적중

강남 절대 1위 · 노원 비중 2위. 번화한 학원가는 비중이 낮다(강남 19위, 송파 17위).

빗나감

관악 절대 3위 · 영등포 비중 1위. 둘 다 가설의 학원가 목록 밖이다.

판정

부분 기각. 미리 정한 반대 결과 수용대로 '학원가 + 비학업 요인' 복합 설명으로 바꾼다.

권고: 노원구·영등포구, 세 번째는 판단 보류

확정 ①

노원구

절대 5위 15,710명 · 비중 2위 18.80%

가설의 '학원가 + 주거지' 패턴과 일치

확정 ②

영등포구

절대 4위 20,223명 · 비중 1위 18.86%

가장 강한 교차 근거. 학원가 통념 밖이라 현장 확인 필요

판단 보류

강남구 또는 중랑구

규모 우선 → 강남구 (절대 1위 27,203명)
집중도 우선 → 중랑구 (비중 3위 18.55%)

정책 목적(최대 다수 vs 효율)으로 결정

근거 절대 상위5 ∩ 비중 상위5 = 노원구 · 영등포구 (둘뿐)

한계

1. **하루치 · 가공 데이터**
   2026-04-15 하루, 오류를 일부러 넣은 교육용 데이터. 실제 서울 경향과 다를 수 있다.
2. **생활인구 ≠ 거주인구**
   그 구에 있던 10대가 그 구 주민인지, 통학해 온 학생인지 구분할 수 없다.
3. **우리가 정한 기준**
   15~17시는 피크가 아닌 우리의 '방과후' 정의. 분모 보정에 비중 순위가 21/25 바뀌었다.

▶ 직접 해보기 · 상호작용 차트

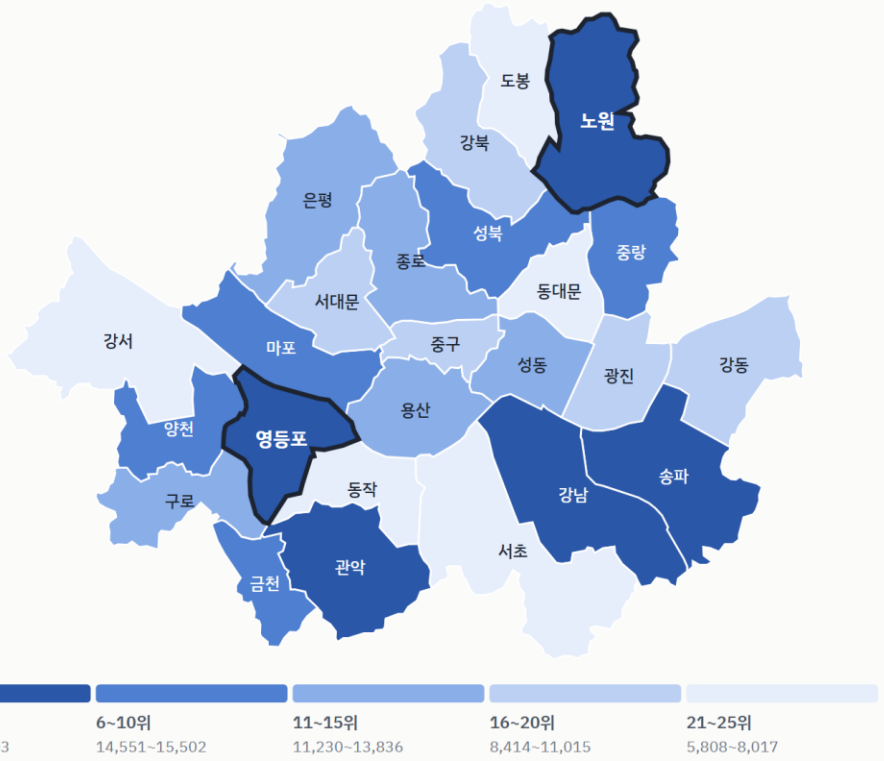
14조 미션D · 방과후(15~17시) 10대 생활인구 · 정제 후

어디에 많고, 어디에 몰려 있나

왼쪽 절대(10대 합계) · 오른쪽 비중(전 연령 대비 10대) · 순위 5개씩 5단계 · 굵은 테두리 = 노원구·영등포구 · 분모 보정함

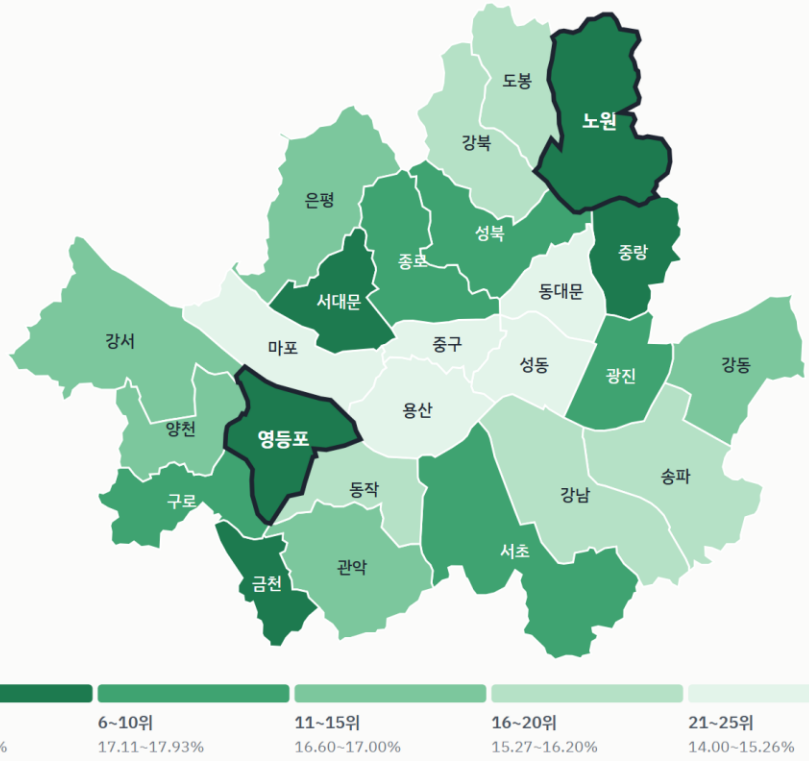
202103116-stack.github.io/youth-space-seoul-analysis/slides/charts
휴대폰으로 찍으면 바로 열립니다

절대 · 10대 합계(명)



1~5위	6~10위	11~15위	16~20위	21~25위
15,710~27,203	14,551~15,502	11,230~13,836	8,414~11,015	5,808~8,017

비중 · 전 연령 대비 10대(%)



1~5위	6~10위	11~15위	16~20위	21~25위
17.97~18.86%	17.11~17.93%	16.60~17.00%	15.27~16.20%	14.00~15.26%

생활인구 = 그 시각 그 구에 있던 사람 수(거주인구 아님)

▶ 직접 해보기 · 상호작용 차트

14조 미션D · 방과후(15~17시) 10대 생활인구 · 정제 후

정제 전후 생활인구수 분포

전체 시간대·연령대 · 로그 축 · 상자 = 가운데 50% · 정제 전 n은 숫자로 읽힌 값(빈칸·'-' 195건 제외)

